

SGL 自监督图推荐系统 与 DMLC 改进

Self-supervised Graph Learning — SGL Baseline & DMLC Enhancement

训练进展汇报

2026 年 6 月 4 日

LightGCN — 图构建与归一化

符号:

- N : 用户数, M : 物品数
- d : 嵌入维度, L : GCN 层数
- $\mathbf{U}^{(0)} \in \mathbb{R}^{N \times d}$: 用户初始嵌入
- $\mathbf{I}^{(0)} \in \mathbb{R}^{M \times d}$: 物品初始嵌入
- $\mathbf{A}$: 邻接矩阵, $\mathbf{D}$: 度矩阵
- $\tilde{\mathbf{A}}$: 对称归一化邻接矩阵
- $\mathbf{E}^{(l)}$: 第 l 层节点嵌入
- $\mathcal{N}(u)$: 用户 u 的邻居物品集

1. 邻接矩阵 (用户-物品二部图):

$$\mathbf{A} = \begin{pmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^\top & \mathbf{0} \end{pmatrix}, \quad \mathbf{R}_{ui} = 1 \text{ 若交互过}$$

2. 对称归一化:

$$\tilde{\mathbf{A}} = \mathbf{D}^{-\frac{1}{2}} \mathbf{A} \mathbf{D}^{-\frac{1}{2}}, \quad \tilde{\mathbf{A}}_{ui} = \frac{1}{\sqrt{|\mathcal{N}(u)| \cdot |\mathcal{N}(i)|}}$$

LightGCN — 传播与输出

3. LightGCN 传播 (去非线性):

$$\mathbf{E}^{(0)} = [\mathbf{U}^{(0)}; \mathbf{I}^{(0)}]$$

初始嵌入拼接

$$\mathbf{E}^{(l+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(l)}$$

聚合邻居信息, $l = 0, \dots, L - 1$

节点级展开:

$$\mathbf{e}_u^{(l+1)} = \sum_{i \in \mathcal{N}(u)} \frac{\mathbf{e}_i^{(l)}}{\sqrt{|\mathcal{N}(u)| |\mathcal{N}(i)|}}, \quad \mathbf{e}_i^{(l+1)} = \sum_{u \in \mathcal{N}(i)} \frac{\mathbf{e}_u^{(l)}}{\sqrt{|\mathcal{N}(i)| |\mathcal{N}(u)|}}$$

用户 u 聚合相连物品嵌入; 物品 i 聚合相连用户嵌入

4. 各层平均 (最终表示):

$$\mathbf{E} = \frac{1}{L+1} \sum_{l=0}^L \mathbf{E}^{(l)}, \quad \mathbf{e}_u = \frac{1}{L+1} \sum_{l=0}^L \mathbf{e}_u^{(l)}, \quad \mathbf{e}_i = \frac{1}{L+1} \sum_{l=0}^L \mathbf{e}_i^{(l)}$$

L : GCN 层数, 共 $L+1$ 层 (含第 0 层初始嵌入)

SGL 创新 — 为什么要两个子图？

对比学习的核心思想：让同一个节点在不同视角下的表示保持一致

为什么需要两个子图？

- 如果只有一个图，无从对比——没有“正样本对”的概念
- 把原图 $\mathcal{G}$ 做两次不同随机增强，得到 $\tilde{\mathcal{G}}_1, \tilde{\mathcal{G}}_2$
- 同一用户 u 在这两个子图中的嵌入 (e'_u, e''_u) 构成正样本对
- 对比学习的目标：模型要学会忽略增强带来的噪声，抓住图的本质结构

类比（图像领域）：

一张猫图 $\xrightarrow{\text{随机裁剪/翻转}}$ 图 A(猫) 和图 B(猫) $\rightarrow$ 模型学出“都是同一只猫”
一张猫图 $\xrightarrow{\text{裁剪/翻转}}$ 图 A(猫) 和图 C(狗) $\rightarrow$ 模型区分“猫和狗不同”

图推荐同理：同一用户的交互模式在两个子图中被不同地丢弃边，但模型要认出是同一个用户

增强方式（配置 `aug_type` 三选一，做两次随机应用）：

ND (Node Dropout):

以概率 p 丢节点及其全部连边

ED (Edge Dropout):

以概率 p 随机丢弃 $|\mathcal{E}|p$ 条边

RW (Random Walk):

每层 GCN 独立随机丢边

SGL — 前向流程 & InfoNCE 损失

完整前向:

$$\mathcal{G} \xrightarrow{\text{增强}} \{\tilde{\mathcal{G}}_1, \tilde{\mathcal{G}}_2\} \xrightarrow{\text{LightGCN}} \{\mathbf{E}_1, \mathbf{E}_2\} \xrightarrow{\text{采样}} \{\mathbf{e}'_u, \mathbf{e}''_u, \mathbf{e}'_i, \mathbf{e}''_i\} \xrightarrow{\text{InfoNCE}} \mathcal{L}_{\text{SSL}}$$

执行步骤:

- ① 原图 $\mathcal{G}$ 经同一增强方法做两次随机应用得子图 $\tilde{\mathcal{G}}_1, \tilde{\mathcal{G}}_2$
- ② 共享权重的 LightGCN 分别编码, 得两组嵌入 $\mathbf{E}_1, \mathbf{E}_2$
- ③ 对 batch 中每个用户 u , 从两组嵌入取出对应向量 $\mathbf{e}'_u, \mathbf{e}''_u$
- ④ $(\mathbf{e}'_u, \mathbf{e}''_u) = \text{正样本对}$ (同一用户跨视图)
- ⑤ batch 内其他用户 $\{\mathbf{e}''_v\}_{v \neq u} = \text{负样本}$
- ⑥ InfoNCE 拉近正样本对、推远负样本对

InfoNCE 对比损失:

$$\mathcal{L}_{\text{SSL}}^u = - \sum_u \log \frac{\exp(\mathbf{e}'_u{}^\top \mathbf{e}''_u / \tau)}{\sum_{v \in \mathcal{U}} \exp(\mathbf{e}'_u{}^\top \mathbf{e}''_v / \tau)} \quad \text{用户侧}$$

$$\mathcal{L}_{\text{SSL}}^i = - \sum_i \log \frac{\exp(\mathbf{e}'_i{}^\top \mathbf{e}''_i / \tau)}{\sum_{j \in \mathcal{I}} \exp(\mathbf{e}'_i{}^\top \mathbf{e}''_j / \tau)} \quad \text{物品侧}$$

- $\mathbf{e}'_u$: 子图 1 的用户嵌入, $\mathbf{e}''_u$: 子图 2 的用户嵌入
- v 遍历当前 batch 中所有用户 (含 u 自己), j 同理遍历所有物品
- 分子: u 和自己的相似度; 分母: u 和全部用户相似度之和
- 整个分数 $\rightarrow$ 概率: u 在所有人中正确认出自己的概率
- τ : 温度系数, 控制分布的集中程度

SGL — BPR 主任务 & 总损失

BPR 主任务 (Bayesian Personalized Ranking):

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u,i,j)} \log \sigma(\mathbf{e}_u^\top \mathbf{e}_i - \mathbf{e}_u^\top \mathbf{e}_j)$$

- (u, i, j) : 用户 u 交互过 i 、未交互过 j
- $\mathbf{E}$ 由原图 $\mathcal{G}$ 经 LightGCN 编码 (非子图)
- 意义: 让正样本得分 $\mathbf{e}_u^\top \mathbf{e}_i$ 高于负样本 $\mathbf{e}_u^\top \mathbf{e}_j$

SGL 总损失:

$$\mathcal{L}_{\text{SGL}} = \underbrace{\mathcal{L}_{\text{BPR}}}_{\text{排序任务}} + \lambda_1 \underbrace{\mathcal{L}_{\text{SSL}}}_{\text{跨视图对比}} + \lambda_2 \underbrace{\|\Theta\|_2^2}_{\text{L2 正则}}$$

- BPR: 主任务, 学习用户对物品的偏好排序
- SSL (InfoNCE): 辅助任务, 学习跨视图不变表征
- $\|\Theta\|_2^2$: L2 正则化防止过拟合
- λ_1, λ_2 : 平衡系数

DMLC — Deep Multi-Layer Contrastive with Warmup

符号: $\mathbf{E}_1^{(l)}$: 视图 1 第 l 层嵌入, $\mathbf{E}_2^{(l)}$: 视图 2 第 l 层嵌入

改进 1 — 多层对比学习 (MLC):

- 原版 SGL: 先对各层取平均 $\mathbf{E} = \frac{1}{L+1} \sum \mathbf{E}^{(l)}$, 再做 1 次 InfoNCE
- MLC: 对每层输出 $\mathbf{E}^{(l)}$ 分别做 InfoNCE, 再取平均 $\rightarrow$ 共 $L+1$ 次

$$\mathcal{L}_{\text{MLC}} = \frac{1}{L+1} \sum_{l=0}^L \left[- \sum_u \log \frac{\exp(\mathbf{e}_{u,1}^{(l)\top} \mathbf{e}_{u,2}^{(l)}/\tau)}{\sum_v \exp(\mathbf{e}_{u,1}^{(l)\top} \mathbf{e}_{v,2}^{(l)}/\tau)} - \sum_i \log \frac{\exp(\mathbf{e}_{i,1}^{(l)\top} \mathbf{e}_{i,2}^{(l)}/\tau)}{\sum_j \exp(\mathbf{e}_{i,1}^{(l)\top} \mathbf{e}_{j,2}^{(l)}/\tau)} \right]$$

改进 2 — SSL Warmup: 前 $T_{\text{warmup}} = 10$ epoch 权重线性增长

$$w_{\text{ssl}}(t) = \min\left(1.0, \frac{t}{T_{\text{warmup}}}\right)$$

改进 3 — 层加权: 只对深层 ($l \geq l_{\text{start}}$) 做对比, 深层权重更大

$$\mathcal{L}_{\text{MLC}}^w = \sum_{l=l_{\text{start}}}^L w_l \cdot \text{InfoNCE}(\mathbf{E}_1^{(l)}, \mathbf{E}_2^{(l)}), \quad w_l \propto l+1, \quad l_{\text{start}} = 2$$

DMLC 总损失:

$$\mathcal{L}_{\text{DMLC}} = \mathcal{L}_{\text{BPR}} + \lambda w_{\text{ssl}}(t)(\mathcal{L}_{\text{SSL}} + \mathcal{L}_{\text{MLC}}^w) + \lambda_2 \|\Theta\|_2^2$$

$\|\Theta\|_2^2$: L2 正则化, 防止过拟合

SGL 基线 vs DMLC — 实验结果


yelp2018 (31,668 用户, 38,048 物品, 1.6M 交互)

模型	Best Ep	Prec@20	Recall@20	NDCG@20	提升
SGL (基线)	24	0.0300	0.0670	0.0550	—
DMLC (本文)	26	0.0302	0.0682	0.0558	+1.8%


yelp_full (287,116 用户, 150,346 物品, 3.5M 交互)

模型	Best Ep	Prec@20	Recall@20	NDCG@20	提升
SGL (基线)	19	0.0133	0.0947	0.0518	—
DMLC (本文)	6	0.0140	0.0992	0.0545	+4.8%

Recall@20 & NDCG@20 对比



Recall@20



NDCG@20



数据集	指标	SGL (基线)	DMLC (本文)	提升
yelp2018	Recall@20	0.0670	0.0682	+1.8%
	NDCG@20	0.0550	0.0558	+1.5%
yelp_full	Recall@20	0.0947	0.0992	+4.8%
	NDCG@20	0.0518	0.0545	+5.2%

总结

DMLC 三个创新点:

- ① MLC: 每层 GCN 分别做 InfoNCE
- ② SSL Warmup: 前 10 epoch 权重 $0 \rightarrow 1$ 线性增长
- ③ 层加权: 强调深层语义 ($l \geq 2$)

最优成绩:

- yelp2018: +1.8%
- yelp_full: +4.8%